

Санкт-Петербургский Политехнический университет
Петра Великого

«Прикладная математика и информатика»

Отчёт по математической статистике
Лабораторная работа №3 на тему
«Боксплот Тьюки и анализ выбросов»

Студент:	Вайндрах Елизавета
Группа:	5030102/30202
Преподаватель:	Баженов Александр Николаевич

1. Постановка задачи

Целью данной лабораторной работы является изучение метода визуализации одномерных распределений с помощью боксплота Тьюки, а также анализ выбросов в выборках из различных распределений.

Для достижения поставленной цели необходимо решить следующие задачи:

- сгенерировать выборки объема $n=20$ и $n=100$ для заданных распределений;
- построить боксплоты Тьюки для каждой выборки;
- определить долю выбросов в выборках;
- экспериментально оценить среднюю долю выбросов, сгенерировав 1000 выборок;
- проанализировать влияние типа распределения и объема выборки на количество выбросов.

2. Теоретическая часть

○ Используемые распределения

1. Нормальное распределение $N(0,1)$

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x)^2}{2}\right) \quad (1)$$

2. Распределение Коши $C(0,1)$

$$f(x) = \frac{1}{\pi(1+x^2)} \quad (2)$$

3. Распределение Лапласа $L(0, \frac{1}{\sqrt{2}})$

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|} \quad (3)$$

4. Распределение Пуассона $P(5)$

$$f(k) = \frac{5^k e^{-5}}{k!} \quad (4)$$

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases} \quad (5)$$

○ Квартили и медиана

Медиана Q_2 – квантиль $\mu_{\frac{1}{2}}$ (значение, делящее выборку пополам)

Первый квартиль Q_1 – квантиль $\mu_{\frac{1}{4}}$ (значение, ниже которого находится 25% данных.

Первый квартиль Q_3 – квантиль $\mu_{\frac{3}{4}}$ (значение, ниже которого находится 75% данных.

- **Интерквартирный размах**

$$IQR = Q_3 - Q_1 \quad (6)$$

- **Боксплот Тьюки**

Включает в себя:

- Коробку от Q_1 до Q_3 ;
- Линию медианы внутри коробки;
- «усы», ограниченные значениями $Q_1 - 1.5IQR$, $Q_3 + 1.5IQR$.

- **Определение выбросов**

Наблюдение x считается выбросом, если

$$x < Q_1 - 1.5IQR \text{ или } x > Q_3 + 1.5IQR$$

- **Доля выбросов**

Доля выбросов в выборке определяется как:

$$\varepsilon = \frac{N_{\text{выбросов}}}{n} \quad (7)$$

Для повышения точности оценки используется усреднение по множеству выборок:

$$\bar{\varepsilon} = \frac{1}{M} \sum_{i=1}^M \varepsilon_i \quad (8)$$

3. Реализация

Язык программирования: Python.

Среда разработки: PyCharm.

Используемые библиотеки: NumPy, SciPy (scipy.stats), Matplotlib, Pandas.

В программе реализованы следующие функции:

- `tukey_outlier_fraction(sample)` – функция определения выбросов;
- `plot_boxplots()` – функция построения боксплотов;
- `calculate_average_outlier_fractions()` – функция подсчёта средней доли выбросов.

4. Результаты




Рис.1. Боксплоты для нормального распределения




Рис.2. Боксплоты для распределения Коши




Рис.3. Боксплоты для распределения Лапласа




Рис.4. Боксплоты для распределения Пуассона




Рис.5. Боксплоты для равномерного распределения

Распределение	n	Средняя доля выбросов
Normal $N(0,1)$	20	0.02505
Normal $N(0,1)$	100	0.01126
Cauchy $C(0,1)$	20	0.14795
Cauchy $C(0,1)$	100	0.15428
Laplace $L(0, 1/\sqrt{2})$	20	0.06875
Laplace $L(0, 1/\sqrt{2})$	100	0.06486
Poisson $P(5)$	20	0.02640
Poisson $P(5)$	100	0.01383
Uniform $U(-\sqrt{3}, \sqrt{3})$	20	0.00170
Uniform $U(-\sqrt{3}, \sqrt{3})$	100	0.00000

Рис.6. Средняя доля выбросов по 1000 выборкам

5. Обсуждение

Анализ результатов показывает, что количество выбросов существенно зависит от типа распределения.

Распределение Коши характеризуется тяжёлыми хвостами, вследствие чего наблюдается большое количество выбросов. Это связано с тем, что вероятность появления значений, сильно удалённых от центра, достаточно велика.

Нормальное распределение имеет более лёгкие хвосты, поэтому количество выбросов значительно меньше.

Распределение Лапласа занимает промежуточное положение: хвосты тяжелее, чем у нормального распределения, что приводит к увеличению доли выбросов.

Распределение Пуассона является дискретным и асимметричным, при этом экстремальные значения возникают редко, поэтому выбросов практически нет.

Равномерное распределение ограничено конечным интервалом, поэтому выбросы практически отсутствуют.

Также наблюдается влияние объёма выборки:

- при увеличении n оценка становится более стабильной;
- боксплоты становятся более информативными;
- выбросы выявляются более корректно.

6. Выводы

В ходе выполнения лабораторной работы были изучены методы визуализации данных с использованием боксплота Тьюки и проведён анализ выбросов.

Было установлено, что:

- боксплот является эффективным инструментом для анализа распределения и выявления выбросов;
- количество выбросов зависит от свойств распределения, в частности от "тяжести" хвостов;
- распределение Коши даёт наибольшее количество выбросов;
- равномерное распределение практически не содержит выбросов;
- увеличение объёма выборки повышает надёжность статистических оценок.

Полученные результаты согласуются с теоретическими ожиданиями.

7. Приложение

<https://github.com/Vaindrakh-Elizaveta/math-statistics-labs/tree/lab3/MatStat3>