

Санкт-Петербургский Политехнический университет
Петра Великого

«Прикладная математика и информатика»

Отчёт по математической статистике
Лабораторная работа №4 на тему
«Эмпирическая функция распределения
и ядерные оценки плотности»

Студент:	Вайндрах Елизавета
Группа:	5030102/30202
Преподаватель:	Баженов Александр Николаевич

1. Постановка задачи

Целью данной лабораторной работы является изучение свойств эмпирической функции распределения и методов оценки плотности вероятности, а также анализ влияния объёма выборки на точность этих оценок.

Для достижения поставленной цели необходимо решить следующие задачи:

- сгенерировать выборки объёма $n = 20, 60, 100$ для заданных распределений;
- построить эмпирическую функцию распределения и сравнить её с теоретической функцией распределения;
- построить ядерную оценку плотности и сравнить её с теоретической плотностью;
- проанализировать влияние объёма выборки на точность аппроксимации;
- сравнить методы оценки плотности распределения.

2. Теоретическая часть

○ Используемые распределения

1. Нормальное распределение $N(0,1)$

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x)^2}{2}\right) \quad (1)$$

2. Распределение Коши $C(0,1)$

$$f(x) = \frac{1}{\pi(1+x^2)} \quad (2)$$

3. Распределение Лапласа $L(0, \frac{1}{\sqrt{2}})$

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|} \quad (3)$$

4. Распределение Пуассона $P(5)$

$$f(k) = \frac{5^k e^{-5}}{k!} \quad (4)$$

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases} \quad (5)$$

○ **Функция распределения**

Функцией распределения случайной величины X называется функция:

$$F(x) = P(X \leq x) \quad (6)$$

Она обладает следующими свойствами:

- $F(x)$ неубывающая;
- $0 \leq F(x) \leq 1$;
- $\lim_{x \rightarrow -\infty} F(x) = 0$; $\lim_{x \rightarrow +\infty} F(x) = 1$;

Для непрерывных случайных величин функция распределения связана с плотностью вероятности:

$$F(x) = \int_{-\infty}^x f(t) dt \quad (7)$$

○ **Плотность распределения**

$$f(x) = \frac{dF(x)}{dx} \quad (8)$$

Плотность удовлетворяет условиям:

- $f(x) \geq 0$;
- $\int_{-\infty}^{+\infty} f(x) dx = 1$.

Для дискретных распределений вместо плотности используется функция вероятностей:

$$P(X = k) \quad (9)$$

○ **Эмпирическая функция распределения**

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x), \text{ где } I - \text{индикаторная функция} \quad (10)$$

○ **Ядерная оценка плотности**

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) \quad (11)$$

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} \quad (12)$$

3. Реализация

Язык программирования: Python.

Среда разработки: PyCharm.

Используемые библиотеки: NumPy, SciPy (scipy.stats), Matplotlib.

• **Построение эмпирической функции распределения**

Для построения ЭФР:

- 1) выборка сортируется;
- 2) вычисляются значения $\frac{i}{n}$;
- 3) строится ступенчатая функция.

Это соответствует формуле (10).

- **Построение теоретических функций**

Теоретические функции распределения и плотности строятся с использованием методов:

cdf – функция распределения;

pdf – плотность;

pmf – функция вероятностей (для распределения Пуассона).

- **Ядерная оценка плотности**

Для построения KDE используется функция: `gaussian_kde(sample)`.

Для дискретного распределения Пуассона к выборке добавляется небольшой шум для корректной работы метода.

4. Результаты




Рис.1. Функция распределения и ядерная оценка плотности для нормального распределения

Коши $C(0, 1)$




Рис.2. Функция распределения и ядерная оценка плотности для распределения Коши

Лапласа $L(0, 1/\sqrt{2})$




Рис.3. Функция распределения и ядерная оценка плотности для распределения Лапласа

Пуассона P(5)




Рис.4. Функция распределения и ядерная оценка плотности для распределения Пуассона

Равномерное $U(-\sqrt{3}, \sqrt{3})$




Рис.5. Функция распределения и ядерная оценка плотности для равномерного распределения

5. Обсуждение

Анализ результатов показал, что с увеличением объёма выборки эмпирическая функция распределения всё точнее приближает теоретическую функцию распределения.

Для нормального распределения наблюдается быстрая сходимость как ЭФР, так и ядерной оценки плотности.

Для распределения Коши сходимость происходит медленнее, что связано с тяжёлыми хвостами данного распределения.

Для распределения Лапласа ядерная оценка сглаживает острый пик плотности, что является особенностью метода.

Для распределения Пуассона ядерная оценка представляет собой сглаженное приближение дискретного распределения, поэтому совпадение с теоретической функцией вероятностей не является точным.

Для равномерного распределения наблюдаются краевые эффекты, связанные с тем, что гауссово ядро имеет бесконечную область определения.

6. Выводы

В ходе выполнения лабораторной работы были изучены методы построения эмпирической функции распределения и ядерной оценки плотности.

Было установлено, что:

- эмпирическая функция распределения сходится к теоретической при увеличении объёма выборки;
- ядерная оценка плотности позволяет получить гладкое приближение плотности;
- точность оценок существенно зависит от объёма выборки;
- различные распределения имеют особенности, влияющие на скорость сходимости;
- ядерные методы дают более наглядное представление плотности по сравнению с гистограммами.

7. Приложение

<https://github.com/Vaindrakh-Elizaveta/math-statistics-labs/tree/lab4/MatStat4>