

Санкт-Петербургский Политехнический университет
Петра Великого

«Прикладная математика и информатика»

Отчёт по математической статистике
Лабораторная работа №1, 2 на тему
«Гистограммы и плотности распределений.
Характеристики положения и рассеяния»

Студент:

Вайндрах Елизавета

Группа:

5030102/30202

Преподаватель:

Баженов Александр Николаевич

1. Постановка задачи

В лабораторных работах рассматриваются следующие распределения случайных величин:

- нормальное распределение $N(0,1)$;
- распределение Коши $C(0,1)$;
- распределение Лапласа $L(0, \frac{1}{\sqrt{2}})$;
- распределение Пуассона $P(k;5)$;
- равномерное распределение $U(-\sqrt{3}, \sqrt{3})$.

В лабораторной работе №1 необходимо:

- Сгенерировать выборки объемом $n = 10, 100, 1000$ для каждого распределения.
- Построить гистограмму выборки, теоретическую функцию плотности распределения (или функцию вероятности для дискретного распределения).
- Проанализировать, как изменение объема выборки влияет на форму гистограммы и её приближение к теоретическому распределению.

В лабораторной работе №2 для тех же распределений необходимо:

- Сгенерировать выборки объема $n = 10, 100, 1000$.
- Для каждой выборки вычислить следующие статистические характеристики:
 - выборочное среднее;
 - медиану;
 - полусумму экстремальных элементов;
 - полусумму квартилей;
 - усечённое среднее.
- Повторить генерацию выборок 1000 раз.
- Для каждой характеристики вычислить математическое ожидание и дисперсию.

2. Теоретическая часть

Используемые распределения

1. Нормальное распределение $N(0,1)$

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \quad (1)$$

2. Распределение Коши $C(0,1)$

$$f(x) = \frac{1}{\pi(1+x^2)} \quad (2)$$

3. Распределение Лапласа $L(0, \frac{1}{\sqrt{2}})$

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|} \quad (3)$$

4. Распределение Пуассона $P(5)$

$$f(k) = \frac{5^k e^{-5}}{k!} \quad (4)$$

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases} \quad (5)$$

Статистические характеристики

1. Выборочное среднее

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (6)$$

2. Медиана – квантиль $\mu_{\frac{1}{2}}$

3. Полусумма экстремальных элементов

$$z_R = \frac{x_{min} + x_{max}}{2} \quad (7)$$

4. Полусумма квартилей

$$z_Q = \frac{\mu_{\frac{1}{4}} + \mu_{\frac{3}{4}}}{2} \quad (8)$$

5. Усечённое среднее

Усечённое среднее вычисляется после удаления части наименьших и наибольших значений выборки. В работе используется 10% усечение.

Оценка характеристик

После многократных экспериментов вычисляются:

Математическое ожидание оценки: $E(z) = \bar{z}$ (9)

И дисперсия: $D(z) = \overline{z^2} - (\bar{z})^2$ (10)

Результат представляется в виде: $E(z) \pm \sqrt{D(z)}$

3. Реализация

Язык программирования: Python.

Среда разработки: PyCharm.

Используемые библиотеки: NumPy, SciPy (scipy.stats), Matplotlib.

В программе к лабораторной №1 реализованы следующие функции:

- **choose_bins(x)** - определяет число интервалов (бинов) для построения гистограммы по выборке x по правилу Фридмана–Диакониса. Если это невозможно, используется формула Стерджеса.
- **x_grid_from_data(x, kind, dist_obj)** - формирует сетку значений по оси X , на которой затем строится теоретическая кривая распределения. Для больших выборок используются квантили, чтобы ограничить слишком далёкие хвосты, особенно в случае распределения Коши.

Помимо этих функций, в основной части программы выполняются следующие действия:

- создаётся набор распределений, заданных в условии;
- для каждого распределения и каждого объёма выборки генерируется случайная выборка;
- для непрерывных распределений строится гистограмма плотности и теоретическая функция плотности;
- для распределения Пуассона строятся столбцы относительных частот и теоретическая функция вероятности;
- для распределения Коши дополнительно ограничивается диапазон отображения, поскольку это распределение имеет тяжёлые хвосты и может давать экстремальные значения.

В программе к лабораторной №2 реализованы следующие функции:

- **sample_mean(x)** - вычисляет выборочное среднее элементов выборки x по формуле (6).
- **sample_median(x)** - вычисляет медиану выборки x .
- **z_R(x)** - вычисляет полусумму экстремальных элементов выборки по формуле (7).
- **z_Q(x)** - вычисляет полусумму квартилей выборки x по формуле (8).
- **z_tr(x)** - вычисляет усечённое среднее выборки x .
- **calc_statistics(values)** - вычисляет итоговые статистики по набору значений одной и той же характеристики, полученных в результате 1000 повторений эксперимента.

4. Результаты

1. Нормальное распределение




Рис. 1. Гистограммы для нормального распределения

n = 10

Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	-0.010250	0.099753	0.315837	-0.010250 ± 0.315837
med	-0.011481	0.134458	0.366686	-0.011481 ± 0.366686
z_R	-0.006154	0.194218	0.440701	-0.006154 ± 0.440701
z_Q	-0.011676	0.115119	0.339292	-0.011676 ± 0.339292
z_tr	-0.011274	0.103535	0.321769	-0.011274 ± 0.321769

n = 100

Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	-0.003770	0.010295	0.101462	-0.003770 ± 0.101462
med	-0.007257	0.015408	0.124128	-0.007257 ± 0.124128
z_R	0.003412	0.097597	0.312405	0.003412 ± 0.312405
z_Q	-0.003541	0.012887	0.113523	-0.003541 ± 0.113523
z_tr	-0.004878	0.011084	0.105279	-0.004878 ± 0.105279

n = 1000

Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	0.000836	0.000899	0.029979	0.000836 ± 0.029979
med	0.000799	0.001470	0.038337	0.000799 ± 0.038337
z_R	-0.004105	0.065251	0.255442	-0.004105 ± 0.255442
z_Q	0.001976	0.001095	0.033089	0.001976 ± 0.033089
z_tr	0.000986	0.000954	0.030885	0.000986 ± 0.030885

Рис. 2. Данные характеристик для нормального распределения

2. Распределение Коши




Рис.3. Гистограммы для распределения Коши

n = 10				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	0.458394	2652.555347	51.502964	0.458394 ± 51.502964
med	-0.023171	0.337805	0.581210	-0.023171 ± 0.581210
z_R	2.410940	66048.688531	256.999394	2.410940 ± 256.999394
z_Q	-0.053989	1.227658	1.107997	-0.053989 ± 1.107997
z_tr	-0.029743	1.617633	1.271862	-0.029743 ± 1.271862
n = 100				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	1.505644	2553.744147	50.534584	1.505644 ± 50.534584
med	0.000602	0.024448	0.156360	0.000602 ± 0.156360
z_R	73.602144	6357920.397369	2521.491701	73.602144 ± 2521.491701
z_Q	0.006659	0.054117	0.232631	0.006659 ± 0.232631
z_tr	0.007417	0.050677	0.225117	0.007417 ± 0.225117
n = 1000				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	5.416095	17221.525415	131.230810	5.416095 ± 131.230810
med	-0.000809	0.002440	0.049400	-0.000809 ± 0.049400
z_R	2678.178650	4294515930.859868	65532.556267	2678.178650 ± 65532.556267
z_Q	-0.000600	0.004715	0.068663	-0.000600 ± 0.068663
z_tr	-0.000729	0.004559	0.067523	-0.000729 ± 0.067523

Рис.4. Данные характеристик для распределения Коши

3. Распределение Лапласа




Рис.5. Гистограммы для распределения Лапласа

n = 10				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	0.013242	0.104242	0.322865	0.013242 ± 0.322865
med	0.007094	0.074522	0.272987	0.007094 ± 0.272987
z_R	0.008319	0.447626	0.669049	0.008319 ± 0.669049
z_Q	0.013255	0.087428	0.295683	0.013255 ± 0.295683
z_tr	0.014472	0.081596	0.285649	0.014472 ± 0.285649
n = 100				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	-0.000351	0.009447	0.097197	-0.000351 ± 0.097197
med	-0.001505	0.005488	0.074082	-0.001505 ± 0.074082
z_R	0.003141	0.412219	0.642042	0.003141 ± 0.642042
z_Q	-0.002991	0.009283	0.096349	-0.002991 ± 0.096349
z_tr	-0.001581	0.007202	0.084862	-0.001581 ± 0.084862
n = 1000				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	-0.001133	0.001048	0.032378	-0.001133 ± 0.032378
med	-0.001063	0.000553	0.023523	-0.001063 ± 0.023523
z_R	0.005637	0.388020	0.622913	0.005637 ± 0.622913
z_Q	-0.000137	0.001051	0.032423	-0.000137 ± 0.032423
z_tr	-0.000781	0.000781	0.027949	-0.000781 ± 0.027949

Рис.6. Данные характеристик для распределения Лапласа

4. Распределение Пуассона




Рис.7. Гистограммы для распределения Пуассона

n = 10				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	5.006400	0.473079	0.687807	5.006400 ± 0.687807
med	4.873500	0.685248	0.827797	4.873500 ± 0.827797
z_R	5.288000	0.969556	0.984660	5.288000 ± 0.984660
z_Q	4.930875	0.552456	0.743274	4.930875 ± 0.743274
z_tr	4.936000	0.497466	0.705313	4.936000 ± 0.705313
n = 100				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	5.002690	0.048889	0.221109	5.002690 ± 0.221109
med	4.886000	0.107504	0.327878	4.886000 ± 0.327878
z_R	5.962500	0.489344	0.699531	5.962500 ± 0.699531
z_Q	4.884250	0.135977	0.368751	4.884250 ± 0.368751
z_tr	4.908775	0.053179	0.230606	4.908775 ± 0.230606
n = 1000				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	4.999324	0.004646	0.068163	4.999324 ± 0.068163
med	5.000000	0.000000	0.000000	5.000000 ± 0.000000
z_R	6.831500	0.305858	0.553044	6.831500 ± 0.553044
z_Q	4.649250	0.075631	0.275010	4.649250 ± 0.275010
z_tr	4.905721	0.005280	0.072667	4.905721 ± 0.072667

Рис.8. Данные характеристик для распределения Пуассона

5. Равномерное распределение






Рис.9. Гистограммы для равномерного распределения

n = 10				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	0.008397	0.101257	0.318210	0.008397 ± 0.318210
med	0.006934	0.236675	0.486493	0.006934 ± 0.486493
z_R	-0.001944	0.044611	0.211213	-0.001944 ± 0.211213
z_Q	0.011842	0.142538	0.377543	0.011842 ± 0.377543
z_tr	0.010982	0.133296	0.365097	0.010982 ± 0.365097
n = 100				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	-0.000140	0.010475	0.102347	-0.000140 ± 0.102347
med	0.002036	0.030877	0.175718	0.002036 ± 0.175718
z_R	0.000731	0.000568	0.023832	0.000731 ± 0.023832
z_Q	-0.002042	0.015270	0.123574	-0.002042 ± 0.123574
z_tr	-0.000323	0.014580	0.120746	-0.000323 ± 0.120746
n = 1000				
Характеристика	E(z)	D(z)	sqrt(D)	E ± sqrt(D)
$\bar{x}$	-0.000444	0.000999	0.031606	-0.000444 ± 0.031606
med	-0.002097	0.002914	0.053982	-0.002097 ± 0.053982
z_R	-0.000031	0.000006	0.002489	-0.000031 ± 0.002489
z_Q	0.000343	0.001512	0.038885	0.000343 ± 0.038885
z_tr	-0.000609	0.001397	0.037376	-0.000609 ± 0.037376

Рис.10. Данные характеристик для равномерного распределения

5. Обсуждения

В ходе выполнения лабораторных работ были исследованы свойства выборок, полученных из различных распределений: нормального, распределения Коши, распределения Лапласа, распределения Пуассона и равномерного распределения. Для каждого распределения рассматривались выборки объёмом $n=10$, $n=100$ и $n=1000$. Это позволило проследить влияние объёма выборки на форму гистограммы и на поведение статистических характеристик.

Нормальное распределение

Для нормального распределения $N(0,1)$ гистограммы при увеличении объёма выборки постепенно всё точнее приближаются к теоретической кривой плотности. При малом объёме выборки $n=10$ наблюдаются заметные случайные отклонения формы гистограммы от теоретического распределения. Однако при увеличении объёма выборки до $n=100$ и $n=1000$ форма гистограммы становится более гладкой

и симметричной, что соответствует теоретическим свойствам нормального распределения.

Анализ статистических характеристик показывает, что математические ожидания оценок близки к нулю, что соответствует параметрам исходного распределения. При увеличении объёма выборки наблюдается уменьшение дисперсий характеристик и их стандартных отклонений. Это свидетельствует о том, что оценки становятся более устойчивыми и точными.

Распределение Коши

Распределение Коши обладает тяжёлыми хвостами и не имеет математического ожидания и дисперсии. Это отражается в полученных результатах. Гистограммы демонстрируют сильную концентрацию значений около нуля и одновременно наличие редких, но очень больших выбросов.

В таблицах характеристик видно, что выборочное среднее и полусумма экстремальных элементов имеют очень большие значения дисперсий и стандартных отклонений. Это связано с тем, что даже единичные выбросы могут сильно влиять на эти оценки. В то же время медиана, полусумма квартилей и усечённое среднее демонстрируют значительно меньший разброс значений и оказываются более устойчивыми характеристиками центра распределения. Таким образом, для распределений с тяжёлыми хвостами медиана и усечённое среднее оказываются более надёжными оценками, чем обычное среднее.

Распределение Лапласа

Распределение Лапласа имеет более острый пик в центре и более тяжёлые хвосты по сравнению с нормальным распределением. Это хорошо видно на гистограммах: максимум плотности около нуля выражен более резко.

При увеличении объёма выборки форма гистограммы становится всё ближе к теоретической плотности распределения. Значения статистических характеристик также стабилизируются, а их дисперсии уменьшаются. Выборочное среднее, медиана и усечённое среднее дают близкие оценки центра распределения.

Распределение Пуассона

Распределение Пуассона является дискретным распределением, поэтому в работе использовались столбцы относительных частот и теоретическая функция вероятности. При малом объёме выборки наблюдаются заметные случайные отклонения частот от теоретических значений. Однако при увеличении объёма выборки распределение частот всё лучше приближается к теоретической функции вероятности.

Средние значения статистических характеристик близки к параметру распределения $\lambda=5$. При увеличении объёма выборки уменьшается дисперсия оценок, что свидетельствует о повышении точности статистических оценок.

Равномерное распределение

Для равномерного распределения гистограммы имеют приблизительно прямоугольную форму. При малом объёме выборки распределение значений по интервалу выглядит неравномерным, однако при увеличении объёма выборки гистограмма становится всё более равномерной и лучше соответствует теоретической плотности.

Статистические характеристики имеют значения, близкие к нулю, что соответствует центру рассматриваемого распределения. С увеличением объёма выборки дисперсии характеристик уменьшаются, что также подтверждает повышение точности оценок.

Общие наблюдения

Анализ результатов показывает, что увеличение объёма выборки приводит к более точному приближению эмпирических распределений к теоретическим. Это проявляется как в форме гистограмм, так и в уменьшении дисперсий статистических характеристик. Полученные результаты подтверждают основные положения математической статистики.

6. Выводы

- 1) В ходе выполнения лабораторных работ были изучены свойства выборок, полученных из различных распределений случайных величин: нормального, распределения Коши, распределения Лапласа, распределения Пуассона и равномерного распределения.
- 2) Было установлено, что при увеличении объёма выборки эмпирические гистограммы всё лучше приближаются к соответствующим теоретическим функциям плотности или вероятности. Это подтверждает теоретические положения математической статистики.
- 3) Проведённый анализ показал, что статистические характеристики выборки (среднее, медиана, полусумма экстремальных элементов, полусумма квартилей и усечённое среднее) ведут себя по-разному в зависимости от свойств распределения.
- 4) Для распределений с хорошо определёнными моментами (например, нормального и равномерного) выборочное среднее является достаточно точной и устойчивой оценкой центра распределения. При увеличении объёма выборки дисперсия этой оценки уменьшается.
- 5) Для распределений с тяжёлыми хвостами, таких как распределение Коши, выборочное среднее и полусумма экстремальных элементов оказываются крайне нестабильными. В этом случае более надёжными характеристиками центра являются медиана и усечённое среднее.
- 6) Для дискретного распределения Пуассона было показано, что относительные частоты событий при увеличении объёма выборки стремятся к теоретическим вероятностям.
- 7) В целом результаты экспериментов подтверждают, что увеличение объёма выборки повышает точность статистических оценок и уменьшает их разброс.

7. Приложение

<https://github.com/Vaindrakh-Elizaveta/math-statistics-labs>